



Završni zadatak, PR-P-LV3

Upute za rješavanje

1. Riješite dane zadatke koristeći programski jezik Python te pripadajuće biblioteke i metode strojnog učenja koje ste učili u okviru laboratorijskih vježbi. Zadatke rješavajte u skripti `prezime_ispit.py`.
2. Rješenja zadataka, u obliku skripte `prezime_ispit.py`, kao i popunjeni list za odgovore u obliku `prezime_ispit.pdf`, uploadajte na Merlin u jednom `.zip` folderu naziva `prezime_ispit`.

Zadatak 0.0.7 Iris Dataset sastoji se od informacija o laticama i čašicama tri različita cvijeta irisa (Setosa, Versicolour i Virginica). Dostupan je u sklopu biblioteke `scikitlearn`:

```
from sklearn import datasets
iris = datasets.load_iris()
```

Upoznajte se s datasetom i dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Prikažite odnos duljine latice i čašice svih pripadnika klase Virginica pomoću *scatter* dijagrama zelenom bojom. Dodajte na isti dijagram odnos duljine latice i čašice svih pripadnika klase Setosa, sivom bojom. Dodajte naziv dijagrama i nazive osi te legendu. Komentirajte prikazani dijagram.
- b) Pomoću stupčastog dijagrama prikažite najveću vrijednost širine čašice za sve tri klase cvijeta. Dodajte naziv dijagrama i nazive osi. Komentirajte prikazani dijagram.
- c) Koliko jedinki pripadnika klase Setosa ima veću širinu čašice od prosječne širine čašice te klase?

Zadatak 0.0.8 Iris Dataset sastoji se od informacija o laticama i čašicama tri različita cvijeta irisa (Setosa, Versicolour i Virginica). Dostupan je u sklopu biblioteke `scikitlearn`:

```
from sklearn import datasets
```

```
iris = datasets.load_iris()
```

Upoznajte se s datasetom. Pripremite podatke za učenje. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- Pronađite optimalni broj klastera K za klasifikaciju cvijeta irisa algoritmom K srednjih vrijednosti.
- Grafički prikazite lakat metodu.
- Primijenite algoritam K srednjih vrijednosti koji će pronaći grupe u podacima. Koristite vrijednost K dobivenu u prethodnom zadatku.
- Dijagramom raspršenja prikazite dobivene klastere. Obojite ih različitim bojama (zelena, žuta i narančasta). Centroide obojite crvenom bojom. Dodajte nazive osi, naziv dijagrama i legendu. Komentirajte prikazani dijagram.
- Usporedite dobivene klase sa njihovim stvarnim vrijednostima. Izračunajte točnost klasifikacije.

Zadatak 0.0.9 Iris Dataset sastoji se od informacija o laticama i čašicama tri različita cvijeta irisa (Setosa, Versicolour i Virginica). Dostupan je u sklopu biblioteke `scikitlearn`:

```
from sklearn import datasets
iris = datasets.load_iris()
```

Upoznajte se s datasetom. Podijelite ga na ulazne podatke X i izlazne podatke y predstavljene klasom cvijeta. Pripremite podatke za učenje neuronske mreže (kategoričke veličine, skaliranje...). Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 80:20. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- Izgradite neuronsku mrežu sa sljedećim karakteristikama:
 - model očekuje ulazne podatke X
 - prvi skriveni sloj ima 12 neurona i koristi `relu` aktivacijsku funkciju
 - drugi skriveni sloj ima 7 neurona i koristi `relu` aktivacijsku funkciju
 - treći skriveni sloj ima 5 neurona i koristi `relu` aktivacijsku funkciju
 - izlazni sloj ima 3 neurona i koristi `softmax` aktivacijsku funkciju.
 - između prvog i drugog te drugog i trećeg sloja dodajte Dropout sloj s 20%, odnosno 30% izbačenih neurona
 Ispišite informacije o mreži u terminal.
- Podesite proces treniranja mreže sa sljedećim parametrima:
 - **loss** argument: `categorical_crossentropy`
 - **optimizer**: `adam`
 - **metrika**: `accuracy`.
- Pokrenite učenje mreže sa proizvoljnim brojem epoha (pokušajte sa 450) i veličinom batch-a 7.
- Pohranite model na tvrdi disk te preostale zadatke izvršite na temelju učitano modela.
- Izvršite evaluaciju mreže na testnom skupu podataka.
- Izvršite predikciju mreže na skupu podataka za testiranje. Prikazite matricu zabune za skup podataka za testiranje. Komentirajte dobivene rezultate i predložite kako biste ih poboljšali, ako je potrebno.