

II. dio - Upute za rješavanje

1. Riješite dane zadatke koristeći programski jezik Python te pripadajuće biblioteke i metode strojnog učenja koje ste učili u okviru laboratorijskih vježbi. Zadatke rješavajte u skripti `prezime_ispit.py`.
2. Rješenja zadataka, u obliku skripte `prezime_ispit.py`, kao i popunjeni list za odgovore u obliku `prezime_ispit.pdf`, uplodajte na Merlin u jednom .zip folderu naziva `prezime_ispit`. Pokretanjem skripte, svi zadaci se trebaju izvršiti, a komentirani dio koda neće biti bodovan.

Zadatak 0.0.6 Upoznajte se s datasetom Breast Cancer Wisconsin i implementirajte sljedeće funkcionalnosti:

- a) Implementirajte dio koda pomoću kojeg možete odgovoriti na pitanja: Koliko uzoraka sadrži podatkovni skup? Od koliko i kojih različitih veličina (značajki) se sastoji svaki uzorak? Koje su izlazne veličine i koje su njihove moguće vrijednosti?
- b) Prikažite korelacijsku matricu ulaznih veličina.
- c) Usporedite sve ulazne veličine pomoću kutijastih dijagrama. Dodajte nazive osi i naziv dijagrama.
- d) Implementirajte normalizaciju te ponovno prikažite sve ulazne veličine pomoću kutijastih dijagrama. Dodajte nazive osi i naziv dijagrama.

Zadatak 0.0.7 Upoznajte se s datasetom Breast Cancer Wisconsin i dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja: Učitajte dane podatke. Podijelite ih na ulazne podatke X i izlazne podatke y . Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 70:30. Po potrebi izbacite izostale i null vrijednosti. Normalizirajte podatke. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Implementirajte algoritam klasifikacije predložen u prvom dijelu ispita. Pokrenite treniranje i izradite model na temelju skupa podataka za učenje. Vizualizirajte podatkovne primjere i granicu odluke.
- b) Provedite klasifikaciju skupa podataka za testiranje pomoću izgrađenog modela.
- c) Izračunajte točnost, preciznost i odziv klasifikacije na skupu podataka za učenje i skupu podataka za testiranje.
- d) Prikažite matricu zabune na testnom skupu.

Zadatak 0.0.8 Upoznajte se s datasetom Breast Cancer Wisconsin i dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja: Učitajte dane podatke. Podijelite ih na ulazne podatke X i izlazne podatke y . Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 75:25. Po potrebi izbacite izostale i null vrijednosti. Normalizirajte podatke. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Izgradite neuronsku mrežu sa sljedećim karakteristikama:
 - model očekuje ulazne podatke X
 - prvi skriveni sloj ima 16 neurona i koristi `relu` aktivacijsku funkciju
 - drugi skriveni sloj ima 8 neurona i koristi `relu` aktivacijsku funkciju
 - izlazni sloj ima jedan neuron i koristi `sigmoid` aktivacijsku funkciju.
- Ispišite informacije o mreži u terminal.

- b) Podesite proces treniranja mreže sa sljedećim parametrima:
 - loss argument: `binary_crossentropy`
 - optimizer: `adam`
 - metrika: `accuracy`.
- c) Omogućite praćenje učenja pomoću `Tensorboarda`.
- d) Pokrenite učenje mreže sa proizvoljnim brojem epoha (pokušajte sa 50) i veličinom `batch`-a 16. Podijelite trening skup i odvojite 10% za validacijski podskup.
- e) Drastično promijenite veličinu `batch`-a i ponovno pokrenite učenje.
- f) Promatrajte parametre učenja u `Tensorboardu`.
- g) Pohranite model na tvrdi disk te preostale zadatke izvršite na temelju učitano modela.
- h) Izvršite predikciju mreže na skupu podataka za testiranje. Izračunajte klasifikacijske metrike. Prikažite matricu zabune za skup podataka za testiranje.