

II. dio - Upute za rješavanje

1. Riješite dane zadatke koristeći programski jezik Python te pripadajuće biblioteke i metode strojnog učenja koje ste učili u okviru laboratorijskih vježbi. Zadatke rješavajte u skripti `prezime_ispit.py`.
2. Rješenja zadataka, u obliku skripte `prezime_ispit.py`, kao i popunjeni list za odgovore u obliku `prezime_ispit.pdf`, uplodajte na Merlin u jednom .zip folderu naziva `prezime_ispit`. Pokretanjem skripte, svi zadaci se trebaju izvršiti, a komentirani dio koda neće biti bodovan.

Zadatak 0.0.2 Upoznajte se s datasetom The California housing. Implementirajte sljedeće funkcionalnosti:

- a) Implementirajte dio koda pomoću kojeg možete odgovoriti na pitanja: Koliko uzoraka sadrži podatkovni skup? Od koliko i kojih različitih veličina (značajki) se sastoji svaki uzorak? Koja je veličina izlazna i koje su njezine moguće vrijednosti (raspon)?
- b) Podijelite podatke na trening i test skup u omjeru 80:20. Prikažite korelacijsku matricu svih ulaznih veličina. Prikažite korelaciju ulaznih veličina i cijene nekretnine.
- c) Dijagramom raspršenja prikažite ovisnost cijene nekretnina o svim ulaznim veličinama. Svaka ovisnost treba biti na zasebnom grafu, a svi grafovi trebaju biti prikazani na istoj slici. Dodajte nazive osi i nazive grafova. Točke na grafovima obojite zelenom bojom.
- d) Kutijastim dijagramima prikažite distribuciju svih ulaznih veličina.

Zadatak 0.0.3 Upoznajte se s datasetom The California housing.

Učitajte dane podatke. Podijelite ih na ulazne podatke X i izlazne podatke y . Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 80:20. Normalizirajte podatke. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Izgradite model linearne regresije pomoću `scikit-learn` biblioteke na temelju skupa podataka za učenje.
- b) Provedite predikciju cijene nekretnine na skupu podataka za testiranje pomoću izgrađenog modela linearne regresije. Izvršite vrednovanje modela pomoću regresijskih metrika (RMSE, MAE, MAPE i R^2) na skupu podataka za testiranje.
- c) Vizualizirajte ovisnost stvarnih i predviđenih vrijednosti cijena nekretnina. Točke obojite narančastom bojom. Dodajte pravac sive boje koji opisuje idealnu ovisnost ovih veličina.

Zadatak 0.0.4 Upoznajte se s datasetom The California housing.

Učitajte dane podatke. Podijelite ih na ulazne podatke X i izlazne podatke y . Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 80:20. Normalizirajte podatke. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Izgradite neuronsku mrežu sa sljedećim karakteristikama:
 - model očekuje ulazne podatke X
 - prvi skriveni sloj ima 64 neurona i koristi `relu` aktivacijsku funkciju

- drugi skriveni sloj ima 50 neurona i koristi **relu** aktivacijsku funkciju
 - izlazni sloj ima jedan neuron.
- Ispišite informacije o mreži u terminal.
- b) Podesite proces treniranja mreže sa sljedećim parametrima:
 - loss argument: **mse**
 - optimizer: **adam**
 - metrika: **mae**.
 - c) Omogućite praćenje učenja pomoću **Tensorboarda**.
 - d) Pokrenite učenje mreže sa proizvoljnim brojem epoha (pokušajte sa 50) i veličinom **batch**-a 32. Odvojite 10% podataka za validaciju.
 - e) Drastično promijenite veličinu **batch**-a i ponovno pokrenite učenje.
 - f) Promatrajte parametre učenja u **Tensorboardu**.
 - g) Pohranite model na tvrdi disk te preostale zadatke izvršite na temelju učitano modela.
 - h) Izvršite predikciju mreže (**batch size** = 32) na skupu podataka za testiranje. Izvršite vrednovanje modela pomoću regresijskih metrika (RMSE, MAE, MAPE i R2) na skupu podataka za testiranje.