

II. dio - Upute za rješavanje

1. Riješite dane zadatke koristeći programski jezik Python te pripadajuće biblioteke i metode strojnog učenja koje ste učili u okviru laboratorijskih vježbi. Zadatke rješavajte u skripti `prezime_ispit.py`.
2. Rješenja zadataka, u obliku skripte `prezime_ispit.py`, kao i popunjeni list za odgovore u obliku `prezime_ispit.pdf`, uplodajte na Merlin u jednom .zip folderu naziva `prezime_ispit`.

Zadatak 0.0.17 Upoznajte se s datasetom Fashion MNIST i dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Vizualizirajte po jedan primjer iz svake klase. Na sliku dodajte naziv odgovarajuće klase (npr. "Dress").
- b) Prikažite stupčastim dijagramima (na jednoj slici) distribuciju uzoraka svake klase u prvih 10 000 uzoraka podatkovnog skupa i na cijelom podatkovnom skupu. Dodajte naziv dijagrama i nazive osi.

Zadatak 0.0.18 Upoznajte se s datasetom Fashion MNIST.

Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja vezana uz učenje SVM modela:

- a) Učitajte dane podatke. Podijelite skup na ulazne podatke X i izlazne podatke y . Za učenje koristite prvih 10 000 uzoraka. Preoblikujte slike u 1D vektore od 784 elementa. Normalizirajte podatke.
- b) Izgradite SVM model. Koristite RBF kernel. Za početak koristite parametre: `gamma='scale'` i `C=1`. Pokrenite učenje modela na skupu za učenje (prvih 10 000 uzoraka).
- c) Izvršite predikciju izlazne veličine na temelju ulaznih veličina skupa za testiranje. Izvršite vrednovanje modela pomoću matrice zabune i izvještaja o klasifikaciji.
- d) Pronađite optimalne parametre C i γ i ponovno provedite vrednovanje modela.

Zadatak 0.0.19 Upoznajte se s datasetom Fashion MNIST i dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja: Učitajte dane podatke. Podijelite ih na ulazne podatke X i izlazne podatke y . Za učenje koristite samo prvih 10 000 uzoraka. Normalizirajte podatke. Po potrebi enkodirajte oznake izlaznih veličina u kategoričke. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Izgradite konvolucijsku neuronsku mrežu sa sljedećim karakteristikama:
 - model očekuje ulazne podatke X , dimenzije $28 \times 28 \times 1$
 - prvi konvolucijski sloj ima 32 filtera, 3×3 i koristi `relu` aktivacijsku funkciju
 - prvi sloj sažimanja (`MaxPooling2D`) koristi prozor veličine 2×2
 - drugi konvolucijski sloj ima 64 filtera, 3×3 i koristi `relu` aktivacijsku funkciju
 - drugi sloj sažimanja (`MaxPooling2D`) koristi prozor veličine 2×2
 - za ulaz u potpuno povezane slojeve potrebno je izravnati podatke - prvi skriveni sloj ima 64 neurona i koristi `relu` aktivacijsku funkciju
 - izlazni sloj ima 10 neurona i koristi `softmax` aktivacijsku funkciju.
- Ispišite informacije o mreži u terminal.

- b) Podesite proces treniranja mreže sa sljedećim parametrima:
 - loss argument: `categorical_crossentropy`
 - optimizer: `adam`
 - metrika: `accuracy`.
- c) Omogućite praćenje učenja pomoću **Tensorboarda**.
- d) Pokrenite učenje mreže sa proizvoljnim brojem epoha (pokušajte s 5) i proizvoljnom veličinom `batch`-a (pokušajte sa 64). Odvojite 10% podataka u validacijski podskup.
- e) Drastično promijenite veličinu `batch`-a i ponovno pokrenite učenje.
- f) Promatrajte parametre učenja u **Tensorboardu**.
- g) Pohranite model na tvrdi disk te preostale zadatke izvršite na temelju učitano modela.
- h) Izvršite predikciju mreže na skupu podataka za testiranje. Prikažite matricu zabune za skup podataka za testiranje. Dodajte nazive klasa na graf.