

II. dio - Upute za rješavanje

1. Riješite dane zadatke koristeći programski jezik Python te pripadajuće biblioteke i metode strojnog učenja koje ste učili u okviru laboratorijskih vježbi. Zadatke rješavajte u skripti `prezime_ispit.py`.
2. Rješenja zadataka, u obliku skripte `prezime_ispit.py`, kao i popunjeni list za odgovore u obliku `prezime_ispit.pdf`, uplodajte na Merlin u jednom .zip folderu naziva `prezime_ispit`. Pokretanjem skripte, svi zadaci se trebaju izvršiti, a komentirani dio koda neće biti bodovan.

Zadatak 0.0.2 Upoznajte se s datasetom Wine dataset. Implementirajte sljedeće funkcionalnosti:

- a) Implementirajte dio koda pomoću kojeg možete odgovoriti na pitanja: Koliko uzoraka sadrži podatkovni skup? Od koliko i kojih različitih veličina (značajki) se sastoji svaki uzorak? Koja je veličina izlazna i koje su njezine moguće vrijednosti (raspon)?
- b) Ispišite osnovnu statistiku podatkovnog skupa.
- c) Nacrtajte histogram svih značajki. Prikažite ih na istoj slici.
- d) Nacrtajte kutijaste dijagrame svih značajki. Prikažite ih na istoj slici.
- e) Prikažite korelacijsku matricu svih ulaznih veličina pomoću heat mape.

Zadatak 0.0.3 Upoznajte se s datasetom Wine dataset.

Učitajte dane podatke. Podijelite ih na ulazne podatke X i izlazne podatke y . Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 80:20. Normalizirajte podatke. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Izgradite model logističke regresije pomoću `scikit-learn` biblioteke na temelju skupa podataka za učenje.
- b) Izgradite KNN model pomoću `scikit-learn` biblioteke na temelju skupa podataka za učenje. Pronađite optimalne parametre. Istrenirajte model s optimalnim parametrima.
- c) Izgradite SVM modele s linearnim i RBF kernelom pomoću `scikit-learn` biblioteke na temelju skupa podataka za učenje. Pronađite optimalne parametre. Istrenirajte model s optimalnim parametrima.
- d) Izračunajte klasifikacijske metrike i prikažite matricu zabune za sve modele.
- e) Primijenite algoritam K-means s 3 klastera na skalirane ulazne značajke.
- f) Na testnom skupu usporedite dobivene klastere sa stvarnim oznakama klasa.
- g) Metodom lakta procijenite optimalni broj klastera.

Zadatak 0.0.4 Upoznajte se s datasetom Wine dataset.

Učitajte dane podatke. Podijelite ih na ulazne podatke X i izlazne podatke y . Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 80:20. Normalizirajte podatke. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Izgradite neuronsku mrežu sa sljedećim karakteristikama:
 - model očekuje ulazne podatke X
 - prvi skriveni sloj ima 16 neurona i koristi `relu` aktivacijsku funkciju

- drugi skriveni sloj ima 8 neurona i koristi **relu** aktivacijsku funkciju
 - izlazni sloj ima tri neurona i koristi **softmax** aktivacijsku funkciju.
- Ispišite informacije o mreži u terminal.
- b) Podesite proces treniranja mreže sa sljedećim parametrima:
 - loss argument: **categorical_crossentropy**
 - optimizer: **adam**
 - metrika: **accuracy**.
 - c) Omogućite praćenje učenja pomoću **Tensorboarda**.
 - d) Pokrenite učenje mreže sa proizvoljnim brojem epoha (pokušajte sa 50) i veličinom **batch**-a 16. Odvojite 10% podataka za validaciju.
 - e) Promatrajte parametre učenja u **Tensorboardu**.
 - f) Pohranite model na tvrdi disk te preostale zadatke izvršite na temelju učitano modela.
 - g) Izvršite predikciju mreže na skupu podataka za testiranje. Izvršite vrednovanje modela pomoću klasifikacijskih metrika na skupu podataka za testiranje. Prikažite matricu zabune.