



Završni zadatak, PR-P-LV4

Upute za rješavanje

1. Riješite dane zadatke koristeći programski jezik Python te pripadajuće biblioteke i metode strojnog učenja koje ste učili u okviru laboratorijskih vježbi. Zadatke rješavajte u skripti `prezime_ispit.py`.
2. Rješenja zadataka, u obliku skripte `prezime_ispit.py`, kao i popunjeni list za odgovore u obliku `prezime_ispit.pdf`, uploadajte na Merlin u jednom `.zip` folderu naziva `prezime_ispit`.

Zadatak 0.0.10 Datoteka `winequality-red.csv` sadrži kemijska mjerenja crnih vina i njihovu kvalitetu. Upoznajte se s datasetom. Više informacija nalazi se u datoteci `winequality.names`.

Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Na koliko je vina provedeno mjerenje?
- b) Prikažite histogramom distribuciju alkoholne jakosti (*alcohol*). Sami izaberite broj *binova*. Dodajte naziv dijagrama i nazive osi. Interpretirajte rezultate prikazane dijagramom.
- c) Koliki broj uzoraka vina ima kvalitetu manju od 6, a koliki ima 6 i veću?
- d) Izračunajte i prikažite korelaciju svih veličina dostupnih u datasetu. Interpretirajte rezultate.

Zadatak 0.0.11 Datoteka `winequality-red.csv` sadrži kemijska mjerenja crnih vina i njihovu kvalitetu. Upoznajte se s datasetom. Više informacija nalazi se u datoteci `winequality.names`. Učitajte dane podatke. Podijelite skup na ulazne podatke X i izlazne podatke y predstavljene kvalitetom vina. Zamijenite sve vrijednosti kvalitete vina manje od 6 s 0, a one koje imaju vrijednost 6 ili veću s 1 kako biste dobili dvije izlazne klase. Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 80:20. Standardizirajte podatke. Dodajte programski kod u skriptu pomoću kojeg možete odgovoriti na sljedeća pitanja:

- a) Izgradite linearni regresijski model. Ispišite parametre modela.
- b) Izvršite procjenu izlazne veličine na temelju ulaznih veličina skupa za testiranje. Prikažite pomoću dijagrama raspršenja odnos između stvarnih vrijednosti izlazne veličine i procjene dobivene modelom. Interpretirajte dobivene rezultate.

- c) Izvršite vrednovanje modela na način da izračunate vrijednosti regresijskih metrika ($RMSE$, MAE , $MAPE$ i R^2) na skupu podataka za testiranje. Interpretirajte dobivene rezultate.

Zadatak 0.0.12 Datoteka `winequality-red.csv` sadrži kemijska mjerenja crnih vina i njihovu kvalitetu. Upoznajte se s datasetom. Više informacija nalazi se u datoteci `winequality.names`. Učitajte dane podatke. Podijelite skup na ulazne podatke X i izlazne podatke y predstavljene kvalitetom vina. Zamijenite sve vrijednosti kvalitete vina manje od 6 s 0, a one koje imaju vrijednost 6 ili veću s 1 kako biste dobili dvije izlazne klase. Podijelite podatke na skup za učenje i skup za testiranje modela u omjeru 80:20. Pripremite podatke za učenje.

- a) Izgradite neuronsku mrežu sa sljedećim karakteristikama:
- model očekuje ulazne podatke X
 - prvi skriveni sloj ima 22 neurona i koristi `relu` aktivacijsku funkciju
 - drugi skriveni sloj ima 12 neurona i koristi `relu` aktivacijsku funkciju
 - treći skriveni sloj ima 4 neurona i koristi `relu` aktivacijsku funkciju
 - izlazni sloj ima jedan neuron i koristi `sigmoid` aktivacijsku funkciju.
- Ispišite informacije o mreži u terminal.
- b) Podesite proces treniranja mreže sa sljedećim parametrima:
- **loss** argument: `binary_crossentropy`
 - **optimizer**: `adam`
 - **metrika**: `accuracy`.
- c) Pokrenite učenje mreže sa proizvoljnim brojem epoha (pokušajte s 800) i proizvoljnom veličinom batch-a (pokušajte s 50).
- d) Pohranite model na tvrdi disk te preostale zadatke izvršite na temelju učitano modela.
- e) Izvršite evaluaciju mreže na testnom skupu podataka.
- f) Izvršite predikciju mreže na skupu podataka za testiranje. Prikažite matricu zabune za skup podataka za testiranje. Interpretirajte dobivene rezultate.